


שעור 6 BML - רגרסיה עם ריבוי פונקציות בסיס

November 29, 2022

יש לנו אוסף נקודות $D = \{x_i, y_i\}$ - x_i הוא התאריך ו- $y(x_i)$ הטמפרטורה ביום הזה.



כרגיל $y(x) = \sum_n \theta_n h_n(x)$, אם יש לנו פריור $\theta \sim \mathcal{N}(0, \Sigma_\theta)$ אז $\theta^{MMSE} = (\frac{1}{\sigma^2} H^T H + \Sigma_\theta^{-1})^{-1} \frac{1}{\sigma^2} H^T y$ יש לנו N פונקציות בסיס ו- I דוגמאות $D = \{x_i, y_i\}_{i=1}^I$, המטריצה $C_{\theta|y} = (\frac{1}{\sigma^2} H^T H + \Sigma_\theta^{-1})^{-1}$ היא בגודל $N \times N$, כלומר כדי לחשב את θ^{MMSE} עבור בסיס פולינום ממעלה 9 צריך להפוך מטריצה בגודל 10×10 .

בגישה הקלאסית נדרוש $N \gg I$: למשל עבור בסיס P_9 יש 10 פרמטרים חופשיים לכן נדרוש לפחות 100 דגימות. לעומת זאת, בגישה הבייסיאנית אנחנו מאפשרים גם מצב של $N \gg I$. **דוגמא:** תמונות ממצלמות רכב - $x \in \mathbb{R}^m$ תמונות של 100^2 פיקסלים, $y \in \mathbb{R}$ מרחק של רכב מהמצלמה בתמונה x .

נגדיר פונקציות בסיס באופן $\{h_{mn}(x) \triangleq x(m)x(n)\}$, זה סימטרי ולכן יהיו לנו $N = \frac{n(n+1)}{2} = \frac{10^4 \cdot 10^4}{2} \approx 5 \cdot 10^7$ כלומר 50 מיליון פונקציות בסיס. בעיה טיפוסית: יש לנו $I = 10^3$ דוגמאות ו- $N = 50 \cdot 10^6$ פיצ'רים. חישוב של θ^{MMSE} דורש היפוך של מטריצה בגודל $N \times N$ וכך גם החישוב של $C_{\theta|y}$. הכלי הראשון שיש לנו להתמודד איתו הוא למת היפוך המטריצה (ידועה גם בתור Woodbury Matrix Identity):

$$\theta^{MMSE} = \Sigma_\theta H^T (H \Sigma_\theta H^T + \sigma^2 I)^{-1} y$$

המכפלה $H \Sigma_\theta H^T$ היא בגודל $I \times I$ וכבר צמצמנו את הקושי החישובי בהיפוך, אבל הוקטור θ עדיין בגודל N והמטריצה $C_{\theta|y}$ עדיין בגודל $N \times N$. **משפט הדואליות:** לכל בעית רגרסיה לינארית בייסאנית פרימאלית עם

$$y_i = y_\theta(x) + \eta, \quad y_\theta(x) = \sum_n \theta_n h_n(x), \quad \theta \sim \mathcal{N}(0, \Sigma_\theta), \quad \eta \sim \mathcal{N}(0, \sigma^2)$$

קיימת בעיית רגרסיה לינארית דואלית עם

$$y_i = y_\alpha(x) + \eta, \quad y_\alpha(x) = \sum_i \alpha_i k(x, x_i), \quad \alpha \sim \mathcal{N}(0, K^{-1}), \quad \eta \sim \mathcal{N}(0, \sigma^2)$$

כאשר

$$k(x, x_i) \triangleq h^T(x) \Sigma_\theta h(x_i), \quad K_{i,j} \triangleq k(x_i, x_j)$$

$$f_{\alpha^{MMSE}}(x) = f_{\theta^{MMSE}}(x) \text{ למעשה לכל } x.$$

הוכחה:

$$\theta^{MMSE} = C_\theta H^T (H C_\theta H^T + \sigma^2 I)^{-1} y, \quad y_\alpha(x) = \sum_i \alpha_i k(x, x_i) \text{ ביחס לנוסחה של } y$$

נציב הפעם

$$C_\alpha = K^{-1}, \quad H = H^T = K, \quad y = K\alpha + \eta$$

ונקבל:

$$\alpha^{MMSE} = K^{-1} K (K K^{-1} K^T + \sigma^2 I)^{-1} y = (K + \sigma^2 I)^{-1} y$$

$$f_{\theta^{MMSE}}(x) = h^T(x) \theta^{MMSE} \text{ וכן } f_{\alpha^{MMSE}}(x) = \sum_i \alpha_i^{MMSE} k(x, x_i) \text{ אנחנו יודעים כי}$$

נציב:

$$\begin{aligned} f_{\theta^{MMSE}}(x) &= h^T(x) \theta^{MMSE} = h^T(x) C_\theta H^T (H C_\theta H^T + \sigma^2 I)^{-1} y \\ &= h^T(x) C_\theta H^T (K + \sigma^2 I)^{-1} y = h^T(x) C_\theta H^T \alpha^{MMSE} = \sum_i \alpha_i^{MMSE} k(x, x_i) = f_{\alpha^{MMSE}}(x) \end{aligned}$$

נחזור לדוגמא: $h_{mn}(x) \triangleq x(m)x(n)$ וכן θ_{mn}^{MMSE} לעומת זאת $y_\theta(x) = \sum_{m,n} \theta_{mn} h_{mn}(x)$ על פניו, כדי לחשב את $k(x, x_i)$ צריך לחשב את $h(x)$ שהם $y_\alpha(x) = \sum_i \alpha_i k(x, x_i)$ וקטורים באורך $5 \cdot 10^7$. נסמן את x_i בתור דוגמת אימון ו- x דוגמא חדשה, נניח כי $C_\theta = I$ ונקבל:

$$\begin{aligned} k(x, x_i) &= h^T(x) h(x_i) = \sum_{m,n} x(m)x(n)x_i(m)x_i(n) \\ &= \sum_m x(m)x_i(m) \sum_n x(n)x_i(n) = \sum_m x(m)x_i(m) (x^T x_i) = (x^T x_i)^2 \end{aligned}$$

וזו כבר עלות ריבועית בגודל התמונה.
הטריק הזה נקרא The Kernel Trick: אם אלגוריתם למידה ניתן לכתובה רק ע"י חישוב של הפונקציה $k(x, x_i)$ אז אין צורך לחשב את $h(x), h(x_i)$.
דרישות מ- k :

1. סימטריה: $k(x, x_i) = k(x_i, x)$

2. חיוביות: $k(x_i, x_i) > 0$

3. המטריצה K חיובית ממש

לכן למשל $k = \sin^3(x - x_i)$ לא יכול להיות קרנל, כי $\sin^3(0) = 0$
 $k(x_i, x_i) = \sin^3(x_i - x_i) = \sin^3(0) = 0$